Proyecto final

Modelo lineal para la puntuación IMDb

Valentina Rodríguez Blanco, Macarena Perdomo, Sol Astengo

Tabla de contenidos

1 Introduccion **1**
- 1.1 Exploracion de datos . . . 1
- 1.2 Metodología . . . 2
  - 1.2.1 Diagnostico . . . 2
  - 1.2.2 Inferencia . . . 3
  - 1.2.3 Desempeño Predictivo . . . 3

2 Modelo inicial **3**

3 Diagnostico **3**
- 3.1 Mulicolinealidad . . . 3
- 3.2 Linealidad . . . 5
- 3.3 Homocedasticidad . . . 8
- 3.4 Normalidad . . . 15
- 3.5 Datos Atípicos . . . 16
- 3.6 Datos Influyentes . . . 17
- 3.7 Conclusiones . . . 18

4 Inferencia **18**
- 4.1 Coeficientes . . . 19
  - 4.1.1 Para las variables de los generos: . . . 19
  - 4.1.2 Para la certificación de una pelicula: . . . 19
  - 4.1.3 Para las variables desnudos, violencia y terror: . . . 20

5 Desempeño Predictivo **20**

1 Introduccion

El objetivo de este trabajo es ajustar un modelo de regresión múltiple que explique la puntuaciónn IMDb. La base de datos contiene información de distintas películas, incluyendo el año de estreno, la cantidad de votos, los géneros, la certificación y variables relacionadas con el contenido, como desnudos, violencia, palabrotas, alcohol y terror.

1.1 Exploracion de datos

La base de datos contiene información sobre películas de IMDb, incluyendo la puntuación media, el año de estreno, la cantidad de votos, los géneros, la certificación y distintas variables asociadas al contenido de la película, se comienza con 4227 pero se eliminan las observaciones que contengan NA y se concluye trabajar con 3931 películas.

La variable respuesta del análisis es `puntuacion`, que representa la puntuación media otorgada por los usuarios. Dentro de las variables explicativas numéricas se consideran `anio`, que indica el año de estreno de la película, y `votos`, que corresponde a la cantidad de votos recibidos.

Los géneros se encuentran representados mediante variables *dummies*, es decir, variables que toman el valor 1 si la película pertenece a ese género y 0 en caso contrario. Además, se creó la variable `Others`, que agrupa los géneros `Documentary`, `Family`, `Film-Noir`, `History`, `Music`, `Musical`, `Romance`, `Sci-Fi`, `Short`, `Sport`, `War` y `Western`, ya que cada uno de estos presentaba menos de 30 películas asociadas.

También se incluyen variables cualitativas relacionadas con la certificación y el contenido de las películas. En particular, las variables `certificacion`, `desnudos`, `violencia`, `palabrotas`, `alcohol` y `terror` fueron transformadas a factor para ser incorporadas correctamente al modelo lineal.

1.2 Metodología

Una vez depurado el conjunto de datos, con todas las variables se define un modelo inicial, que pasará por una etapa de diagnóstico, para así verificar los supuestos necesarios para inferir, mejorando el modelo a medida que progresa esta etapa. Una vez concluido el diagnóstico, se recurre al Summary (Que infiere con el t-valor), para decidir a través de la significación, qué variables se mantendrán en el modelo. Finalmente se realiza una simulación de mil repeticiones donde se obtiene un vector con el coeficiente de determinación estimado en cada experimento, para luego comparar su mediana con el coeficiente de determinación obtenido del Summary y evaluar el desempeño predictivo del modelo.

1.2.1 Diagnostico

El diagnóstico permite evaluar si el modelo ajustado cumple razonablemente con los supuestos del modelo lineal.

1.2.1.1 Mulicolinealidad

Se evalúa la multicolinealidad mediante los factores de inflación de varianza (VIF), con el objetivo de detectar variables explicativas fuertemente relacionadas entre sí. En caso de encontrar valores elevados, se considera eliminar alguna variable del modelo.

1.2.1.2 Linealidad

La linealidad se analiza mediante gráficos de residuos contra valores ajustados y gráficos parciales de residuos. A partir de estos gráficos se busca detectar patrones sistemáticos que indiquen que alguna variable requiere una transformación.

1.2.1.3 Homocedasticidad

La homocedasticidad se evalúa mediante gráficos de residuos studentizados y pruebas formales como Breusch-Pagan. Si se detecta heterocedasticidad, se consideran transformaciones del modelo o el uso de errores estándar robustos.

1.2.1.4 Normalidad

La normalidad de los residuos se estudia mediante pruebas de hipótesis y gráficos Q-Q, con el objetivo de analizar si los residuos presentan un comportamiento compatible con una distribución normal.

1.2.1.5 Datos Atípicos

Los datos atípicos se identifican a partir de los residuos studentizados, buscando observaciones con errores particularmente grandes respecto al comportamiento general del modelo.

1.2.1.6 Datos Influyentes

Los datos influyentes se analizan mediante medidas como el leverage y la distancia de Cook, que permiten detectar observaciones con mayor peso sobre el ajuste del modelo.

1.2.2 Inferencia

La inferencia se realiza sobre el modelo seleccionado mediante el resumen del ajuste (`summary`). A partir de los coeficientes estimados, sus errores estándar, estadísticos t y p-valores, se analiza qué variables presentan evidencia de asociación significativa con la puntuación de las películas.

1.2.3 Desempeño Predictivo

Con el objetivo de evaluar la capacidad predictiva del modelo, se realiza una simulación tomando una particion aleatoria de los datos en cada prueba. En cada iteración se utiliza el 80% de las observaciones para ajustar el modelo y el 20% restante para evaluar las predicciones. Este procedimiento se repite 1000 veces y, en cada partición, se calcula el coeficiente de determinación (R^2) entre las puntuaciones observadas y las predichas.

2 Modelo inicial

Se crea modelo con todas las variables explicativas que incluye el data set.

```
mod1 <- lm(puntuacion ~ anio + votos + Action + Adventure + Animation
           + Biography + Comedy + Crime  + Drama + Fantasy + Horror +
             Mystery + Thriller + Others + certificacion + desnudos +
             violencia + palabrotas + alcohol + terror, data = datos)
```

3 Diagnostico

3.1 Mulicolinealidad

Tabla 1: VIF - mod1

	GVIF	Df	GVIF^(1/(2*Df))
anio	1.172	1	1.083
votos	1.255	1	1.120
Action	10.706	1	3.272
Adventure	3.387	1	1.840
Animation	3.481	1	1.866
Biography	3.465	1	1.862
Comedy	9.078	1	3.013
Crime	3.996	1	1.999
Drama	8.195	1	2.863
Fantasy	1.340	1	1.158
Horror	4.425	1	2.104

Mystery	1.162	1	1.078
Thriller	1.030	1	1.015
Others	1.123	1	1.060
certificacion	1.257	3	1.039
desnudos	1.625	3	1.084
violencia	4.718	3	1.295
palabrotas	2.388	3	1.156
alcohol	1.821	3	1.105
terror	4.854	3	1.301

En la tabla 1 se visualiza que la variable `Action` presenta un VIF superior a 10, por lo que se ajusta un nuevo modelo excluyéndola.

```
mod2 <- lm(puntuacion ~ anio + votos + Adventure + Animation + Biography
           + Comedy + Crime  + Drama + Fantasy + Horror + Mystery + Thriller
           + Others + certificacion + desnudos + violencia + palabrotas +
             alcohol + terror, data = datos)
```

Se investiga multicolinealidad del nuevo modelo

Tabla 2: VIF - mod2

	GVIF	Df	GVIF^(1/(2*Df))
anio	1.164	1	1.079
votos	1.255	1	1.120
Adventure	1.199	1	1.095
Animation	1.419	1	1.191
Biography	1.196	1	1.094
Comedy	2.042	1	1.429
Crime	1.215	1	1.102
Drama	1.550	1	1.245
Fantasy	1.038	1	1.019
Horror	1.365	1	1.168
Mystery	1.021	1	1.011
Thriller	1.023	1	1.012
Others	1.022	1	1.011
certificacion	1.237	3	1.036
desnudos	1.621	3	1.084
violencia	4.654	3	1.292
palabrotas	2.388	3	1.156
alcohol	1.821	3	1.105
terror	4.840	3	1.301

Todos los VIF son menores a 5; terror y violencia tienen un VIF cercano a 5, aún así se decide mantenerlas en el modelo ya que no alcanzan el umbral.

3.2 Linealidad

Se analiza la linealidad mediante un gráfico de residuos vs valores ajustados, evaluando la existencia de patrones sistemáticos.

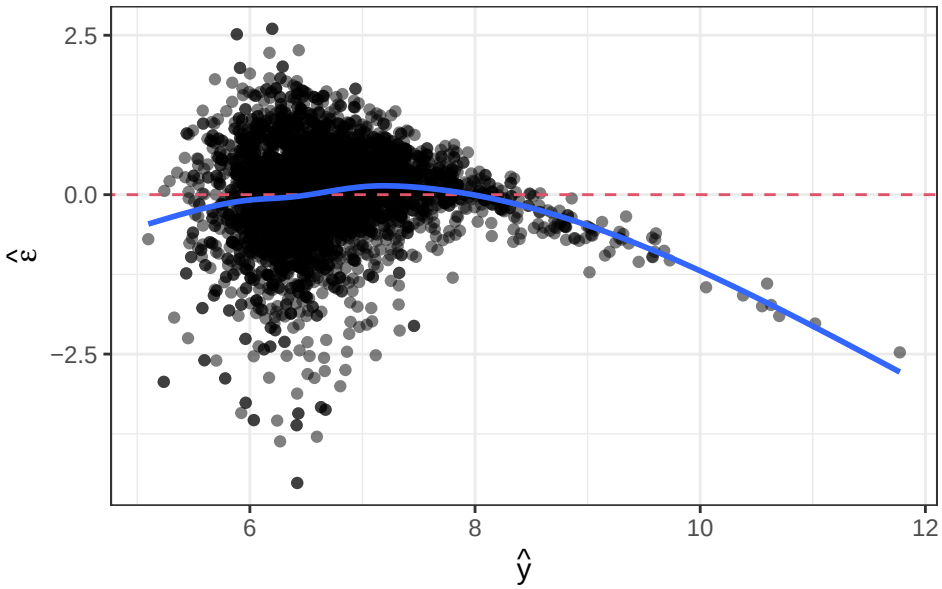


Figura 1: Residuos contra valores ajustados

En la figura 1 se puede observar que el modelo está subestimado en algunas zonas y luego sobreestimado en otras. Se esperaría que los puntos estuvieran dispersos en todo el dominio sin presentar un patron, dado que esto no ocurre, se generan gráficos parciales de los residuos vs los predichos de cada variable explicativa, con el fin de corregir los problemas de linealidad en un nuevo modelo, intentando identificar qué variables explicativas son las que podrían estar generando el patrón presentando.

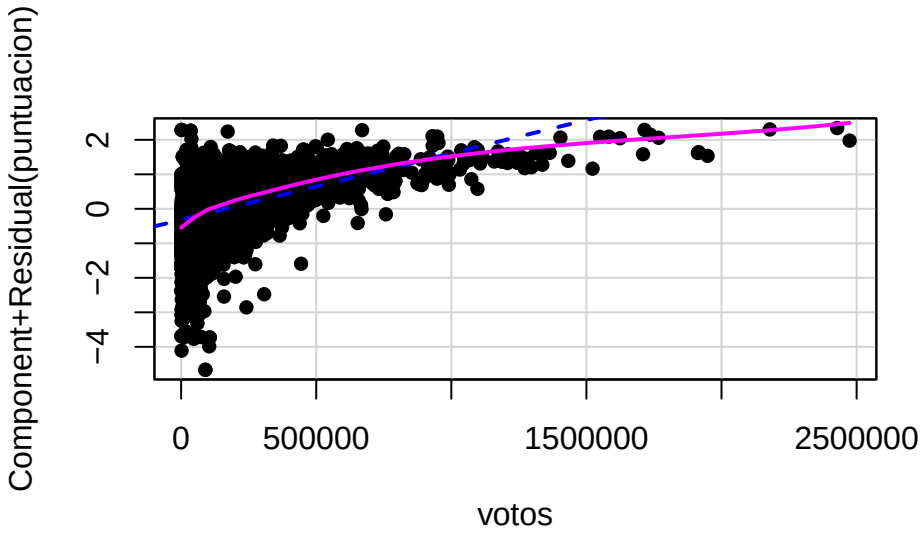


Figura 2: Residuos parciales de votos

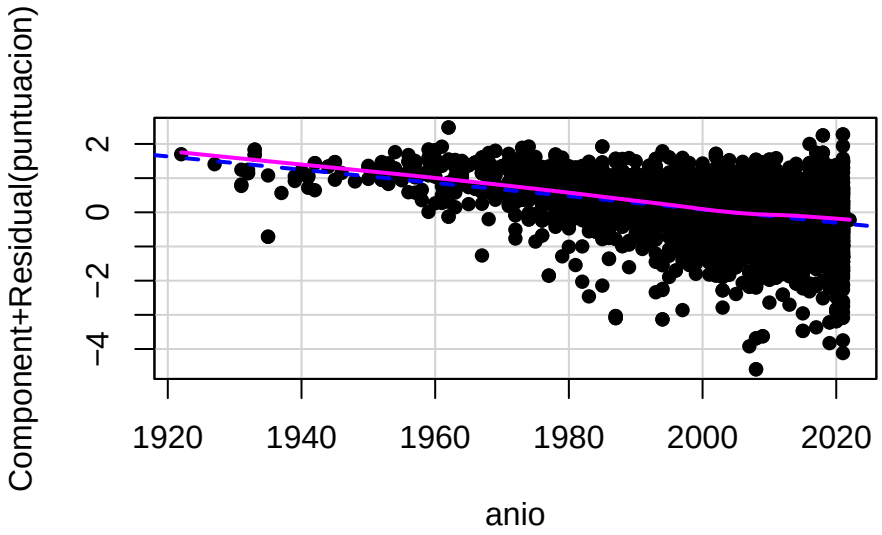


Figura 3: Residuos parciales de anio

En la figura 2 se puede observar que la variable votos presenta un patrón logarítmico, se crea un nuevo modelo con esta variable transformada y se realiza nuevamente el gráfico parcial para

ver si este cambio corrige el problema.

```
mod_log <- lm(
  puntuacion ~ anio + log(votos) +
    Adventure + Animation + Biography + Comedy +
    Crime + Drama + Fantasy + Horror + Mystery + Thriller + Others +
    certificacion + desnudos + violencia + palabrotas + alcohol + terror,
  data = datos
)
```

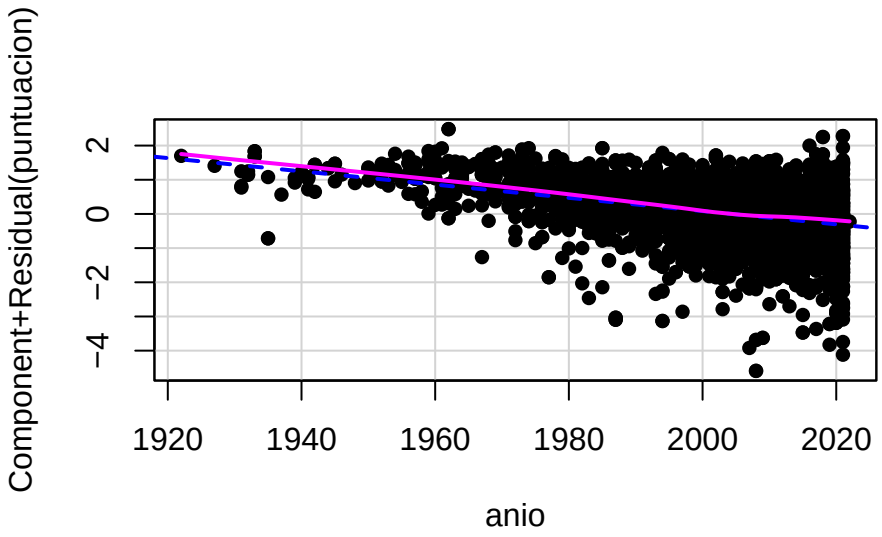


Figura 4: Residuos parciales de log(votos)

Se vuelve a graficar los predichos y los residuos (del nuevo modelo).

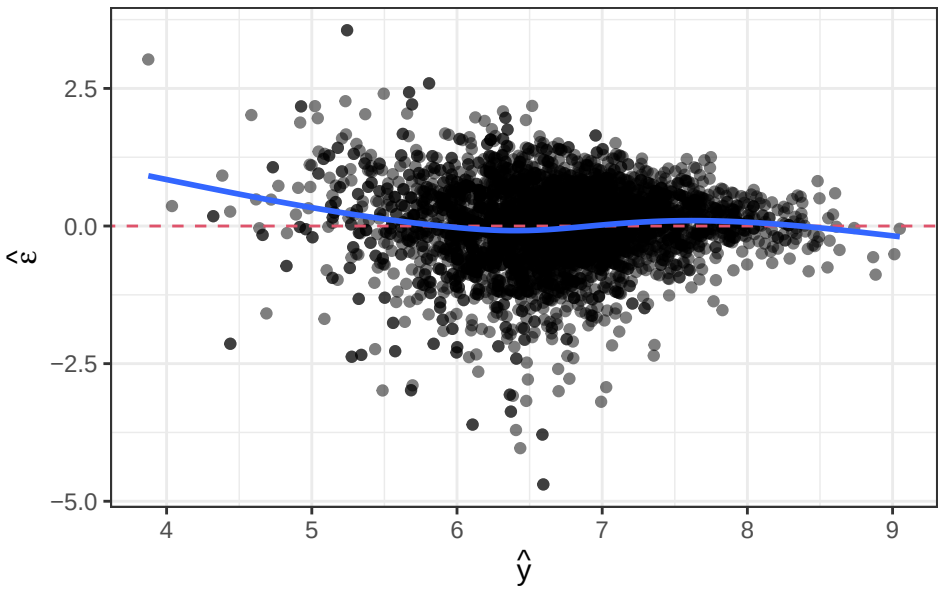


Figura 5: Residuos contra valores ajustados (mod_log)

Con la figura 5 se concluye que este nuevo modelo se observa una mejora en la dispersión de los residuos respecto al modelo anterior, aunque para valores ajustados inferiores a 7 continúa apreciándose una mayor variabilidad.

Con respecto a la variable anio, se realizaron distinas transformaciones intentando desarmar el patron que presentan los graficos parciales, pero no se encontraron mejorías. Por lo tanto no se realizan cambios al respecto y se mantiene el modelo mod_log.

3.3 Homocedasticidad

Se quiere ver si la varianza de los errores es constante, estudiando su independencia con respecto a las variables explicativas. Se agrega una columna al data frame con el calculo de los errores studentizados de cada observacion.

```
datos$t_i <- rstudent(mod_log)    # studentizados EXTERNAMENTE
```

Se grafican Predichos vs Residuos Studentizados, esperando nuevamente no encontrar ningun patron observable a lo largo del dominio.

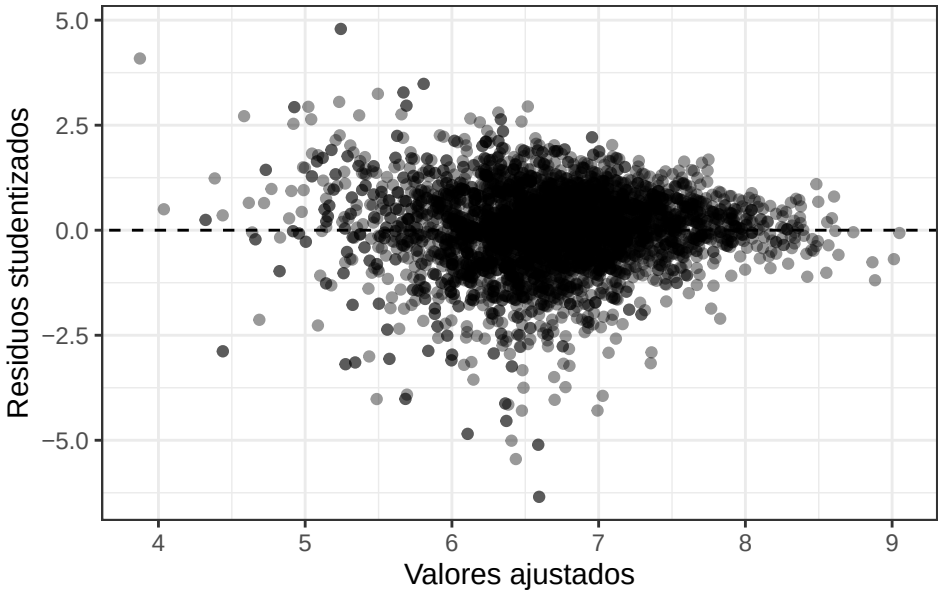


Figura 6: Residuos studentizados contra valores ajustados del modelo con log(votos)

En el grafico 6 se observa heterocedastaticidad debido a que los puntos estan mas dispersos de un lado del grafico, que del otro.

Se realizan test de hipotesis para verificar Homocedasticidad. Teniendo en cuenta que la hipotesis nula establece que los residuos del modelo son homocedasticos, por lo tanto se quiere un p-valor alto.

```
bptest(mod_log)
```

```
    studentized Breusch-Pagan test

data:  mod_log
BP = 237.66, df = 31, p-value < 0.00000000000000022
```

```
breusch_pagan(mod_log)
```

statistic	p.value	parameter	method	alternative
237.6616	0	31	Koenker (studentised)	greater

Los p-valores de ambos test son pequeños, por lo que se rechaza H_0 y se concluye que el modelo es heterocedastico.

Con el fin de identificar que variables son responsables de la heterocedasticidad, se analizan los graficos de los residuos studentizados según cada variable explicativa.

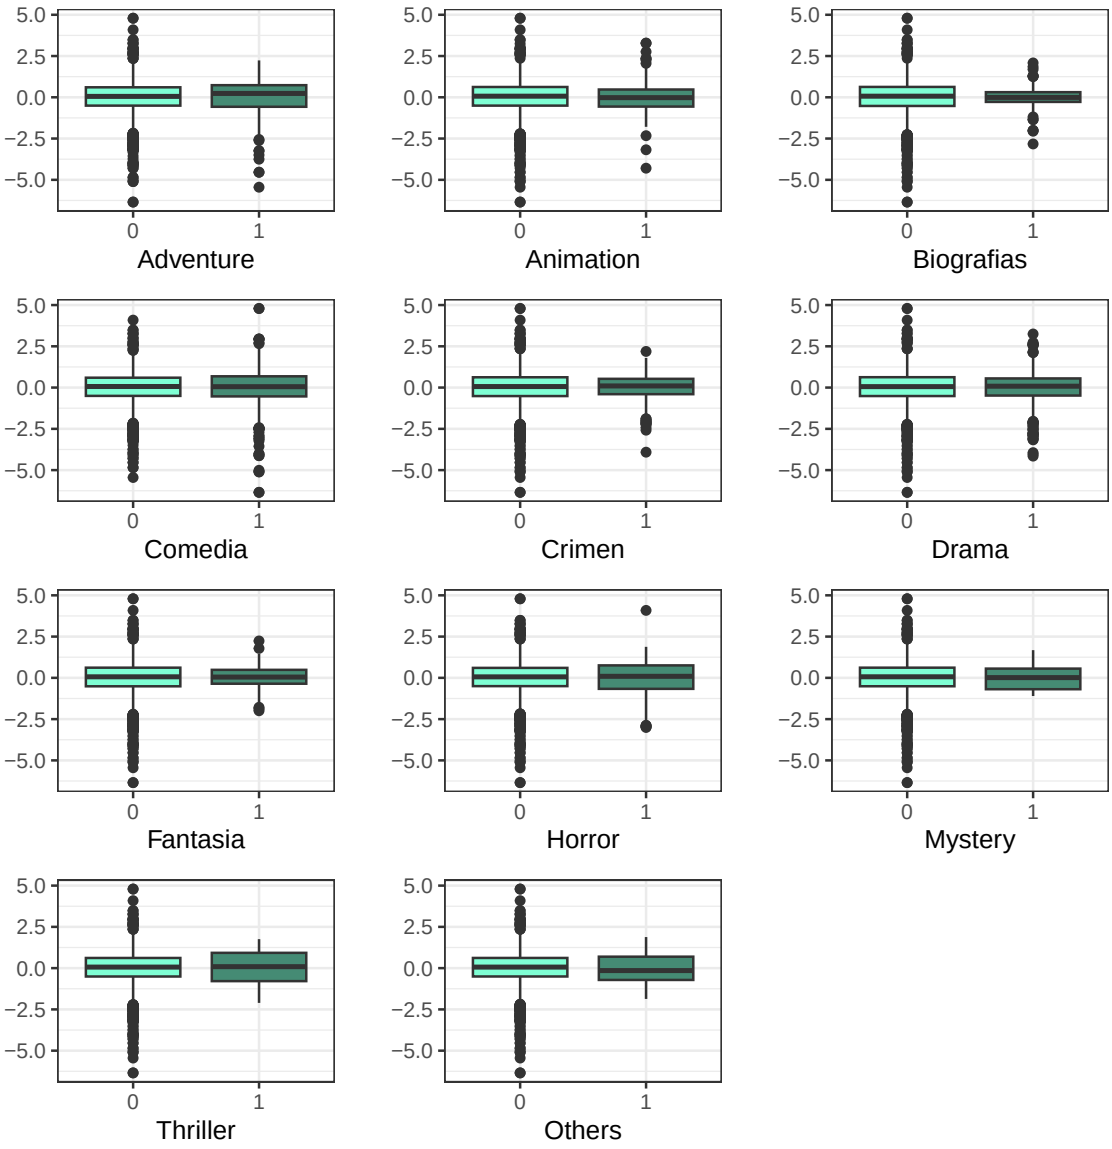


Figura 7: Residuos studentizados según género

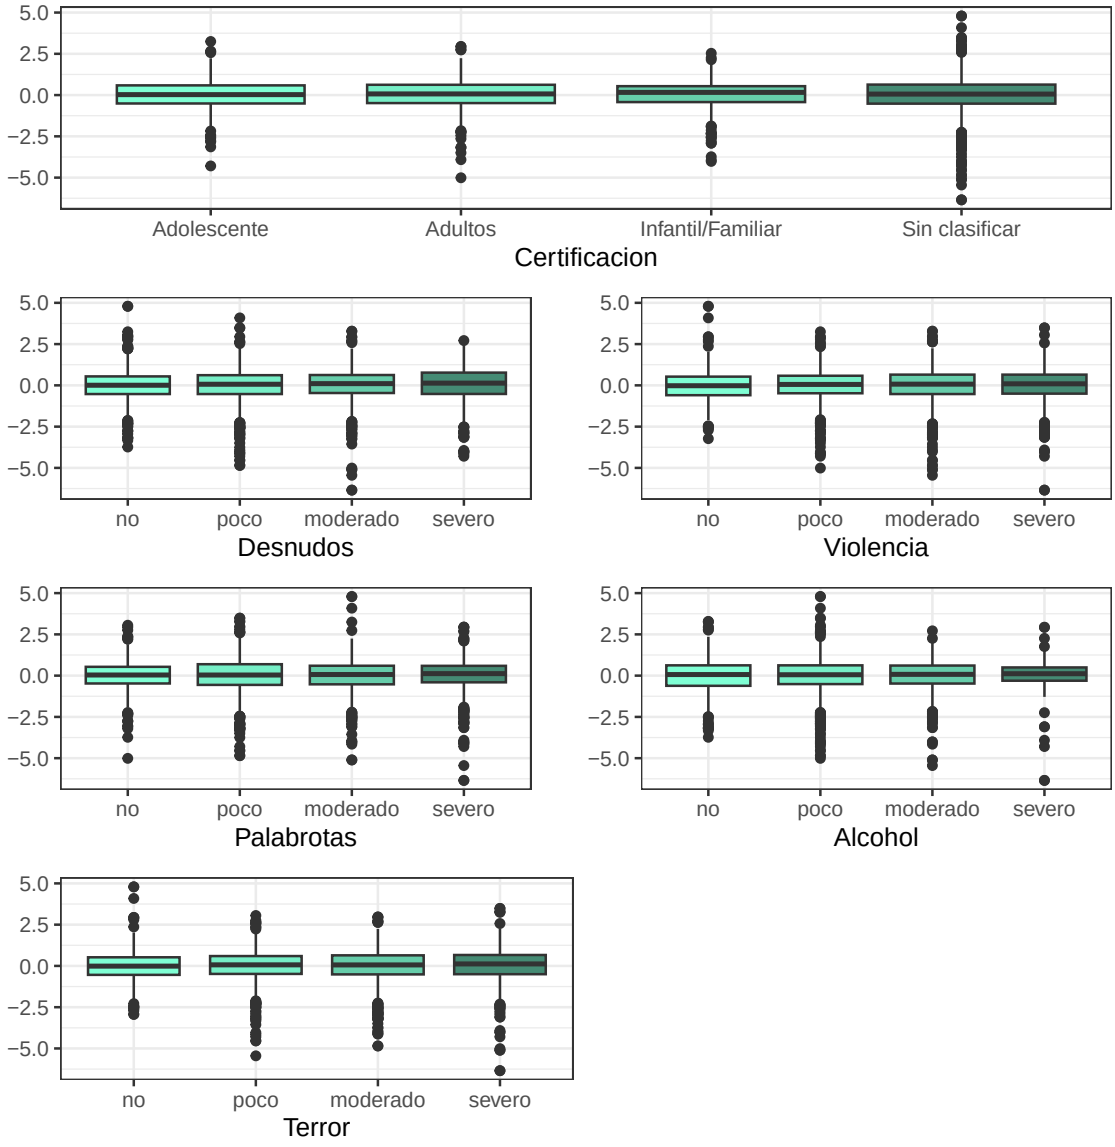


Figura 8: Residuos studentizados según certificación y contenido

En los graficos de errores studentizados con respeto a cada variable cualitativa, se observa variabilidad similar en cada nivel o caja, se ven homocedasticos.

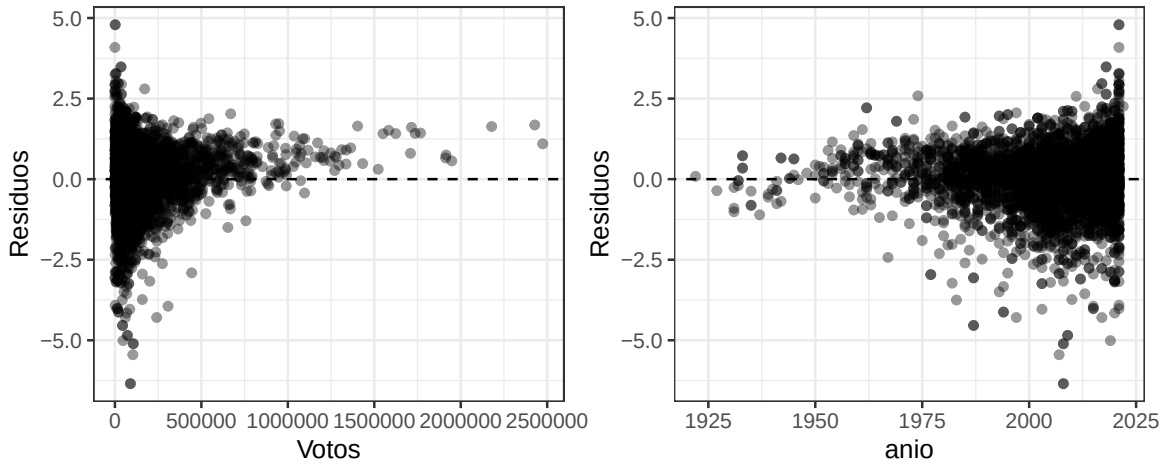


Figura 9: Residuos studentizados según votos y anio

En la figura 9 se ve que las variables numéricas anio y votos presentan un patrón sistemático en los residuos que sugiere heterocedasticidad.

Se busca corregir heterocedasticidad centrando la variable anio respecto a su media.

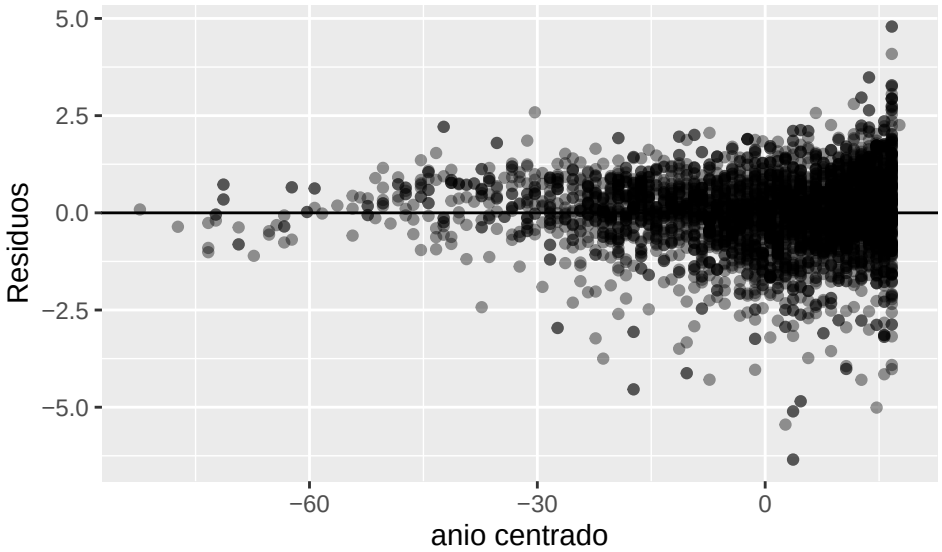


Figura 10: Residuos studentizados según anio centrado

Se define un nuevo modelo con esta nueva transformación:

```r
mod_log_cuad <- lm(
  log(puntuacion) ~ anio_c + I(anio_c^2) + log(votos) +
    Adventure + Animation + Biography + Comedy +
    Crime + Drama + Fantasy + Horror + Mystery + Thriller + Others +
    certificacion + desnudos + violencia + palabrotas + alcohol + terror,
  data = datos
)
```

```r
bptest(mod_log_cuad)
```

```
    studentized Breusch-Pagan test

data:  mod_log_cuad
BP = 189.71, df = 32, p-value < 0.00000000000000022
```

```r
breusch_pagan(mod_log_cuad)
```

statistic	p.value	parameter	method	alternative
189.7061	0	32	Koenker (studentised)	greater

Luego de evaluar distintas transformaciones sobre la variable anio, no se logra corregir la heterocedasticidad. Por este motivo, se mantiene el modelo anterior (mod_log) y se utiliza un estimador de la matriz de covarianza robusto (HC3), para evaluar la significación de las variables explicativas, ya que este no asume homocedasticidad.

Tabla 5: Coeficientes HC3 - mod log

term	estimate	std.error	statistic	p.value
(Intercept)	37.6035	1.4883	25.2668	0.0000
anio	-0.0172	0.0007	-23.4222	0.0000
log(votos)	0.3259	0.0124	26.3393	0.0000
Adventure	0.1096	0.0621	1.7639	0.0778
Animation	0.5558	0.0720	7.7175	0.0000
Biography	0.8991	0.0423	21.2672	0.0000
Comedy	0.1708	0.0467	3.6581	0.0003
Crime	0.5703	0.0457	12.4882	0.0000
Drama	0.5965	0.0381	15.6648	0.0000
Fantasy	-0.1614	0.1216	-1.3276	0.1844
Horror	-0.2468	0.0572	-4.3132	0.0000
Mystery	0.2864	0.1275	2.2465	0.0247

Thriller	-0.0302	0.1524	-0.1983	0.8428
Others	0.6123	0.1383	4.4275	0.0000
certificacionAdultos	-0.0394	0.0444	-0.8860	0.3757
certificacionInfantil/Familiar	-0.0925	0.0467	-1.9822	0.0475
certificacionSin clasificar	-0.2487	0.0365	-6.8216	0.0000
desnudospoco	-0.1346	0.0308	-4.3663	0.0000
desnudosmoderado	-0.1803	0.0389	-4.6387	0.0000
desnudossevero	-0.3994	0.0620	-6.4384	0.0000
violenciapoco	-0.2640	0.0445	-5.9354	0.0000
violenciamoderado	-0.3661	0.0580	-6.3177	0.0000
violenciasevero	-0.3727	0.0687	-5.4266	0.0000
palabrotaspoco	-0.0792	0.0478	-1.6565	0.0977
palabrotasmoderado	-0.0147	0.0526	-0.2801	0.7794
palabrotassevero	0.0438	0.0636	0.6880	0.4915
alcoholpoco	0.0436	0.0392	1.1115	0.2664
alcoholmoderado	0.0973	0.0508	1.9153	0.0555
alcoholsevero	0.1063	0.0811	1.3099	0.1903
terrorpoco	0.0818	0.0436	1.8759	0.0607
terrormoderado	0.1461	0.0581	2.5129	0.0120
terrorsevero	0.2424	0.0764	3.1703	0.0015

Despues del test, a un nivel de significación del 10%, se eliminan las variables: fantasy, thriller, palabrotas y alcohol del modelo, que en la tabla 5 presentan un p-valor mayor a 0.1.

Tabla 6: Coeficientes HC3 - mod log red

term	estimate	std.error	statistic	p.value
(Intercept)	36.9762	1.3357	27.6836	0.0000
anio	-0.0169	0.0007	-25.6144	0.0000
log(votos)	0.3274	0.0120	27.1924	0.0000
Adventure	0.1035	0.0613	1.6883	0.0914
Animation	0.5562	0.0641	8.6825	0.0000
Biography	0.9226	0.0415	22.2389	0.0000
Comedy	0.1982	0.0469	4.2224	0.0000
Crime	0.5998	0.0450	13.3214	0.0000
Drama	0.6014	0.0375	16.0330	0.0000
Horror	-0.2505	0.0566	-4.4241	0.0000
Mystery	0.2853	0.1281	2.2262	0.0261
Others	0.6176	0.1357	4.5517	0.0000
certificacionAdultos	-0.0408	0.0445	-0.9155	0.3600
certificacionInfantil/Familiar	-0.0878	0.0469	-1.8732	0.0611
certificacionSin clasificar	-0.2433	0.0364	-6.6814	0.0000
desnudospoco	-0.1234	0.0301	-4.0956	0.0000
desnudosmoderado	-0.1436	0.0361	-3.9747	0.0001
desnudossevero	-0.3399	0.0584	-5.8166	0.0000
violenciapoco	-0.2436	0.0441	-5.5193	0.0000
violenciamoderado	-0.3419	0.0574	-5.9575	0.0000
violenciasevero	-0.3093	0.0662	-4.6708	0.0000
terrorpoco	0.0817	0.0439	1.8598	0.0630
terrormoderado	0.1432	0.0581	2.4643	0.0138

terrorsevero	0.2397	0.0762	3.1476	0.0017

3.4 Normalidad

Se evalúa el supuesto de normalidad de los residuos mediante los tests de hipotesis: Shapiro-Wilk, Jarque-Bera y Kolmogorov-Smirnov. En los tres casos, la hipótesis nula establece que los residuos siguen una distribución normal.

```
shapiro.test(datos$t_i)
```

```
    Shapiro-Wilk normality test

data:  datos$t_i
W = 0.96047, p-value < 0.00000000000000022
```

```
tseries::jarque.bera.test(datos$t_i)
```

```
    Jarque Bera Test

data:  datos$t_i
X-squared = 2037.5, df = 2, p-value < 0.00000000000000022
```

```
ks.test(datos$t_i, 'pnorm')
```

```
    Asymptotic one-sample Kolmogorov-Smirnov test

data:  datos$t_i
D = 0.064543, p-value = 0.00000000000001194
alternative hypothesis: two-sided
```

Se rechaza H0 (Rechazo que haya normalidad), los p-valores son diminutos.

```
datos$t_i2 <- rstudent(mod_log_red)   # studentizados EXTERNAMENTE
```

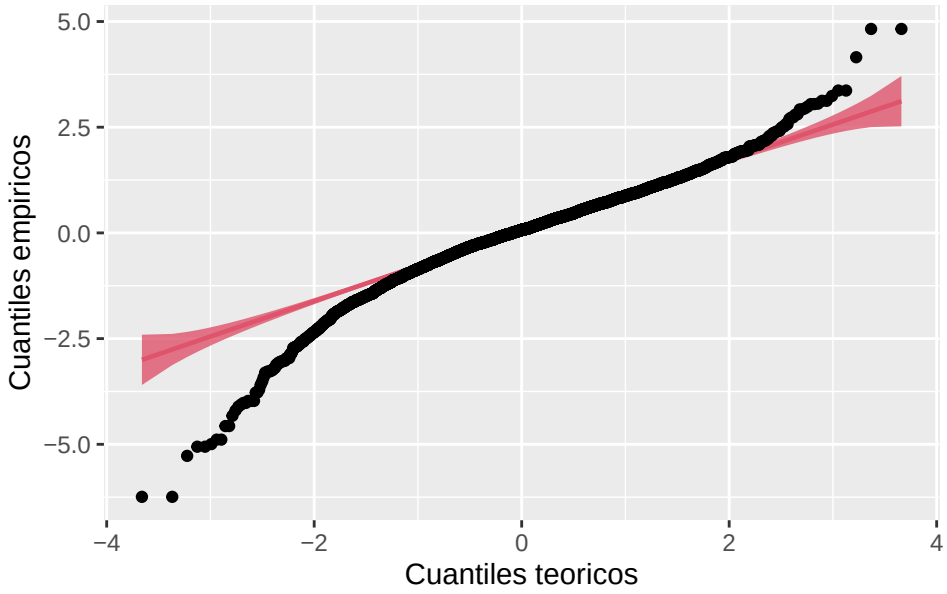


Figura 11: Q-Q Plot

La figura 11 confirma los resultados obtenidos mediante las pruebas de hipotesis de normalidad. Se observa que los residuos se apartan de la recta teórica, principalmente en los extremos de la distribución, lo que evidencia la presencia de colas más pesadas que las esperadas bajo normalidad. Esto sugiere la existencia de observaciones atípicas.

3.5 Datos Atípicos

Se buscan datos atipicos que podrían haber llevado a los test anteriores a rechazar normalidad.

Tabla 7: Datos atípicos - outlierTest

	rstudent	p-valor no ajustado	p-valor Bonferroni
2805	-6.242526	0.000000	0.000002
3580	-6.242526	0.000000	0.000002
2386	-5.273764	0.000000	0.000554
2846	-5.056649	0.000000	0.001754
3621	-5.056649	0.000000	0.001754
234	-4.995148	0.000001	0.002412
3104	-4.889228	0.000001	0.004139
3878	-4.889228	0.000001	0.004139
2605	4.824353	0.000001	0.005732
3380	4.824353	0.000001	0.005732

Este test toma como hipotesis nula que la observación no es atípica, obervando la tabla 7 los resultados se encuentran varios datos atípicos.

3.6 Datos Influyentes

A partir de las observaciones identificadas como atípicas, se analizan el leverage y la distancia de Cook con el objetivo de evaluar su influencia sobre el ajuste del modelo.

Primero, se definen medidas de influencia.

```
h_i <- influence(mod_log_red)$hat
D_i <- cooks.distance(mod_log_red)
df <- data.frame(i = 1:nrow(datos),
                 h_i = h_i,
                 D_i = D_i)

n <- nrow(datos) #Cantidad de observaciones
p <- length(coef(mod_log_red)) #Cantidad de variables explicativas
```

Se estudia leverage. Las observaciones ubicadas por encima de la línea de referencia presentan un leverage elevado y, por lo tanto, tienen mayor potencial de influir en el ajuste del modelo.

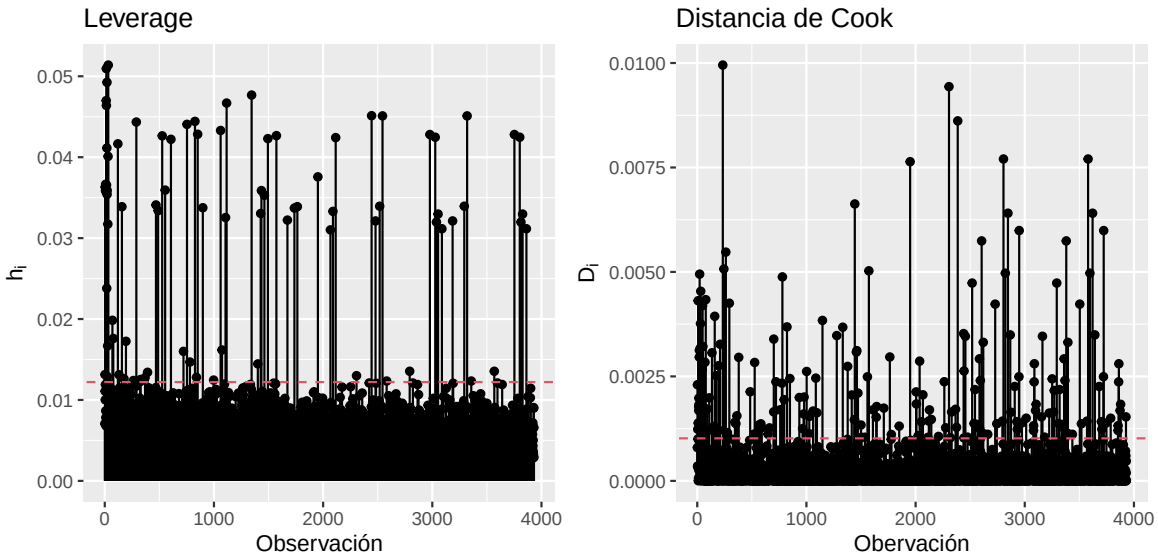


Figura 12: Leverage y Distancia de Cook

Tanto el gráfico de leverage como el de distancia de Cook identifican un número considerable de observaciones potencialmente influyentes. Dado el gran tamaño de la muestra, no se realiza un análisis individual de cada una de ellas y se continúa con el modelo ajustado.

3.7 Conclusiones

Al terminar la etapa de diagnóstico, no se pudo conseguir un modelo que cumpla con el supuesto de normalidad. No obstante, debido a que el número de observaciones es mayor a mil, aún se puede evaluar la significación de las variables con el t-valor. Esto es consecuencia del teorema del límite central, que explica que la distribución de la media de cualquier distribución poblacional, converge a una distribución normal. Como el la hipótesis nula del t-valor asume que las medias poblacionales de dos grupos son iguales, y por Teorema del límite central, se concluye que estas distribuyen normal, se continúa usando los t-valores cómo válidos para inferir.

Luego de realizar el diagnóstico, se selecciona mod_log_red como modelo final. Si bien no fue posible encontrar un modelo que cumpliera todos los supuestos, este fue el que presentó el mejor desempeño luego de las transformaciones y simplificaciones realizadas.

4 Inferencia

Tabla 8: Coeficientes estimados del modelo

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	36.9762	1.6013	23.0915	0.0000
anio	-0.0169	0.0008	-21.4935	0.0000
log(votos)	0.3274	0.0098	33.3092	0.0000
Adventure	0.1035	0.0531	1.9483	0.0514
Animation	0.5562	0.0620	8.9672	0.0000
Biography	0.9226	0.0582	15.8559	0.0000
Comedy	0.1982	0.0418	4.7380	0.0000
Crime	0.5998	0.0515	11.6479	0.0000
Drama	0.6014	0.0380	15.8347	0.0000
Horror	-0.2505	0.0528	-4.7402	0.0000
Mystery	0.2853	0.1514	1.8848	0.0595
Others	0.6176	0.1305	4.7320	0.0000
certificacionAdultos	-0.0408	0.0475	-0.8582	0.3908
certificacionInfantil/Familiar	-0.0878	0.0507	-1.7301	0.0837
certificacionSin clasificar	-0.2433	0.0379	-6.4188	0.0000
desnudospoco	-0.1234	0.0302	-4.0887	0.0000
desnudosmoderado	-0.1436	0.0363	-3.9514	0.0001
desnudossevero	-0.3399	0.0507	-6.7049	0.0000
violenciapoco	-0.2436	0.0482	-5.0573	0.0000
violenciamoderado	-0.3419	0.0585	-5.8474	0.0000
violenciasevero	-0.3093	0.0671	-4.6121	0.0000

terrorpoco	0.0817	0.0465	1.7576	0.0789
terrormoderado	0.1432	0.0558	2.5673	0.0103
terrorsevero	0.2397	0.0668	3.5877	0.0003

Tabla 9: Medidas de ajuste del modelo

Medida	Valor
Número de observaciones	3931.0000
Error estándar residual	0.7486
R^2	0.4219
R^2 ajustado	0.4185
Estadístico F	123.9737
p-valor (F)	0.0000

4.1 Coeficientes

Viendo los resultados de la tabla 8 (summary sin medidas de ajuste) se concluye: ### Para las variables numericas:

Con respecto a la variable *anio*, el $\hat{\beta}$ asociado a esta variable es -0,0169, es decir a medida que año de la pelicula aumenta, su puntuacion disminuye en 0,02 puntos, el p-valor de esta variable es aproximadamente 0, por lo tanto es altamente significativa.

La variable *log(votos)*, tiene un $\hat{\beta}$ de 0,3274, es decir, a medida que aumenta la cantidad de votos de una película, su puntuación aumenta. Debido a que la variable se encuentra transformada mediante logaritmo, este aumento no es constante, sino que se da a un ritmo decreciente. El p-valor de esta variable tambien es aprox. 0, e igualmente es significativa.

4.1.1 Para las variables de los generos:

Se observa que Biography, Crime, Drama, Animation, Others, Mystery, Comedy y Adventure presentan coeficientes positivos, por lo que, manteniendo el resto de las variables constantes, se asocian con una mayor puntuación respecto al género de referencia. En cambio, Horror presenta un coeficiente negativo, indicando una menor puntuación esperada. Todas estas variables resultan significativas al 10%.

4.1.2 Para la certificación de una pelicula:

Unicamente la categoría "Sin clasificar" presenta un efecto negativo estadísticamente significativo sobre la puntuación. La categoría "Infantil/Familiar" resulta significativa al 10%, mientras que la categoría "Adultos" no presenta evidencia suficiente para afirmar que difiere de la categoría de referencia.

4.1.3 Para las variables desnudos, violencia y terror:

Con respecto a la variable *desnudos*, la categoría "No" presenta un coeficiente de 0,1436, indicando que las películas sin desnudos presentan una puntuación esperada 0,1436 puntos mayor que las películas pertenecientes a la categoría de referencia(moderado), manteniendo el resto de las variables constantes. Por otro lado, la categoría "Severo" presenta un coeficiente de -0,1963, asociado a una puntuación esperada 0,1963 puntos menor que la categoría de referencia. La categoría "Poco" no resulta estadísticamente significativa.

La variable *violencia*, la categoría "No" presenta un coeficiente de 0,3419, indicando que las películas sin violencia presentan una puntuación esperada 0,3419 puntos mayor que las películas con violencia moderada, manteniendo el resto de las variables constantes. Por otro lado, la categoría "Poco" presenta un coeficiente de 0,0982, indicando una puntuación esperada ligeramente superior a la categoría de referencia. La categoría "Severo" no resulta estadísticamente significativa, por lo que no se puede afirmar que exista una diferencia con respecto a las películas con violencia moderada.

Con respecto a la variable *terror*, la categoría "No" presenta un coeficiente de -0,1432, indicando que las películas sin contenido de terror presentan una puntuación esperada 0,1432 puntos menor que las películas con contenido de terror moderado, manteniendo el resto de las variables constantes. En cambio, la categoría "Severo" presenta un coeficiente de 0,0965, indicando una puntuación esperada ligeramente superior a la categoría de referencia. La categoría "Poco" no resulta estadísticamente significativa, por lo que no se puede afirmar que exista una diferencia con respecto a las películas con contenido de terror moderado.

5 Desempeño Predictivo

Tabla 10: Resumen del desempeño predictivo

Medida	Valor
Mediana	0.4183
Media	0.4171
DE	0.0277
IC 95% inferior	0.3637
IC 95% superior	0.4697

Se obtuvo una mediana del R^2 de 0,4242 y una media de 0,4233. Además, la desviación estándar fue de 0,0276, lo que indica que el desempeño predictivo del modelo varía poco entre las distintas particiones. El 95% de los valores de R^2 se encontró entre 0,3701 y 0,4774, evidenciando un comportamiento estable del modelo frente a diferentes conjuntos de entrenamiento y prueba.

En promedio el R^2 de las predicciones se aproxima al obtenido en el summary del modelo (tabla 9) que es 0,4219, lo que confirma que la simulación reproduce correctamente el ajuste.

Basandose en el coeficiente de determinación del 40% aprox. se puede afirmar que las predicciones no logran un buen ajuste con respecto a los datos reales.